

Système d'Aide à la Décision pour la Prédiction des Carences en Vitamines

Objectif de prédiction :

Développer un système capable de prédire les carences en vitamines à partir de données cliniques, biologiques et comportementales, puis proposer automatiquement des solutions nutritionnelles ciblées basées sur la base CIQUAL.

Deux approches complémentaires :

► **OPTION 1 : Aide à la Décision Médicale (Curatif)** : Prédire le type de carence en vitamines chez un patient à partir de ses symptômes cliniques, marqueurs biologiques et apports nutritionnels actuels. Une fois la carence identifiée, le système recommande automatiquement des aliments riches en la vitamine manquante via la base CIQUAL.

► **OPTION 2 : Analyse des Modes de Vie et Prévention** : Analyser comment les facteurs comportementaux (fumage, alcool, sédentarité, exposition solaire) et sociodémographiques (âge, genre, localisation géographique) influencent l'apparition de carences. Identifier les patients à risque et proposer des régimes préventifs.

Base de données 1: Vitamin Deficiency Disease Prediction Dataset

[Vitamin Deficiency Disease Prediction Dataset](#)

Contient 4 catégories de variables pour chaque patient :

1. **Facteurs sociodémographiques et comportementaux (10)**: age, gender, BMI, smoking_status, alcohol_consumption, exercise_level, diet_type, sun_exposure, income_level, latitude_region
2. **Apports nutritionnels en % RDA (8)**: vitamin_a, vitamin_c, vitamin_d, vitamin_e, vitamin_b12, folate, calcium, iron
3. **Marqueurs biologiques (4)**: hemoglobin, serum_vitamin_d, serum_vitamin_b12, serum_folate (mesures sanguines réelles)
4. **Données cliniques et symptomatiques (11)**: symptoms_count, symptoms_list, has_night_blindness, has_fatigue, has_bleeding_gums, has_bone_pain, has_muscle_weakness, has numbness_tingling, has_memory_problems, has_pale_skin, **disease_diagnosis** (RÉPONSE À PRÉDIRE), has_multiple_deficiencies

Base de données 2: Table CIQUAL - Composition Nutritionnelle des Aliments (ANSES) [Ciqua](#)

Base officielle française extrêmement détaillée contenant la composition de milliers d'aliments avec:

- **Identificateurs** : codes aliments, groupes alimentaires (viandes, produits laitiers, fruits, légumes, etc.)
 - **Macronutriments** : énergie, eau, protéines, glucides, lipides, fibres, acides gras détaillés
 - **Minéraux (12)** : Calcium, Fer, Magnésium, Zinc, Cuivre, Iode, Phosphore, Potassium, Sélénium, Sodium, Chlorure, Manganèse
 - **Vitamines (18)** : Vitamine A (+ rétinol, beta-carotène), Vitamine C, Vitamine D (D2, D3), Vitamine E, Vitamines K (K1, K2), et toutes les vitamines B (B1, B2, B3, B5, B6, B9/Folates, B12)
-

Diagnostic Assisté de Pneumonie sur Radiographies Thoraciques

Problématique :

Développer un modèle de deep learning capable de détecter automatiquement la présence de pneumonie sur des radiographies thoraciques pédiatriques, afin d'assister les radiologues et médecins dans le diagnostic médical. L'objectif est de classer une image radiographique comme NORMAL ou PNEUMONIA.

Base de données : Chest X-Ray Images (Pneumonia) - Kaggle (5 863 images)

Source: Kaggle - Chest X-Ray Images (Pneumonia) Provenance: Guangzhou Women and Children's Medical Center (patients pédiatriques 1-5 ans) Qualité : Images validées par 2-3 experts radiologues [Chest X-Ray Images \(Pneumonia\)](#)

Organisation :

- 3 dossiers : TRAIN / TEST / VAL
- Sous-dossiers : NORMAL / PNEUMONIA

Caractéristiques des images :

- **Format** : JPEG (radiographies thoraciques antéro-postérieures)
- **Nombre total** : 5 863 images
- **Résolution** : Variable (images médicales en escala de gris)
- **Population** : Enfants de 1 à 5 ans

Deux catégories (labels):

- **NORMAL**: Radiographie sans anomalies, poumons clairs (absence de foyer opaque anormal)
- **PNEUMONIA**: Présence de pneumonie (consolidation focale ou pattern interstitiel diffus)

Types de pneumonie visibles :

- Pneumonie bactérienne : consolidation lobaire focale (zone blanche localisée)

- Pneumonie virale : pattern interstitiel diffus (opacités réparties dans les deux poumons)

Prédiction des Prix Immobiliers en Hérault

OBJECTIF DE PRÉDICTION:

Développer un modèle de prédiction capable d'estimer la valeur foncière (prix de vente) d'un bien immobilier en Hérault en fonction de ses caractéristiques physiques et de sa localisation, permettant une évaluation objective des prix du marché immobilier sur les 5 dernières années.

BASE DE DONNÉES : Données de Valeurs Foncières - Hérault (411 208 transactions)

Source : explore.data.gouv.fr - DVF (Données de Valeurs Foncières) Période : 5 dernières années
Région : Hérault (34) ([Explorateur de données de valeurs foncières - DVF](#))

Variables disponibles (34 colonnes) :

Variables temporelles :

- date_mutation : date de la transaction
- numero_disposition : numéro de la disposition

Variables de transaction :

- nature_mutation : type de mutation (Vente, Échange, Vente en l'état futur d'achèvement, etc.)
- valeur_fonciere : Prix de vente du bien (RÉPONSE À PRÉDIRE !)

Variables de localisation :

- adresse_numero : numéro de la rue
- adresse_suffixe : suffixe (bis, ter, etc.)
- adresse_nom_voie : nom de la rue/voie
- adresse_code_voie : code interne de la voie
- code_postal : code postal (Montpellier, Sète, Béziers, etc.)
- code_commune : code INSEE de la commune
- nom_commune : nom de la commune
- code_departement : code département (34 pour Hérault)
- longitude / latitude : coordonnées GPS précises du bien

Variables cadastrales :

- id_parcelle : identifiant de la parcelle

- ancien_id_parcelle : ancien identifiant (avant réforme)
- numero_volume : numéro de volume en copropriété
- section_prefixe : section cadastrale
- ancien_code_commune / ancien_nom_commune : données historiques

Variables de lots en copropriété :

- nombre_lots : nombre total de lots
- lot1_numero, lot1_surface_carrez / lot2_numero, lot2_surface_carrez / ... / lot5_numero, lot5_surface_carrez
- Surface Carrez (surface utile des lots)

Variables de caractéristiques du bien :

- code_type_local : code du type de bien
- type_local : type de bien (Appartement, Maison, Dépendance, Local commercial, Bureau, etc.)
- surface_reelle_bati : surface réelle bâtie (m²)
- nombre_pieces_principales : nombre de pièces
- code_nature_culture : code de la nature du terrain
- nature_culture : nature du terrain (Terre, Bâtiment, Jardin, etc.)
- code_nature_culture_speciale : code spécialisation
- nature_culture_speciale : spécialisation du terrain
- surface_terrain : surface totale du terrain (m²)

Classification Automatique de Déchets

Objectif de prédiction:

Classifier une image de déchet en 6 catégories : CARTON, VERRE, MÉTAL, PAPIER, PLASTIQUE ou TRASH (déchets non recyclables). Le modèle permettra d'automatiser le tri des déchets, d'améliorer l'efficacité des centres de recyclage et de contribuer à la gestion environnementale durable des matériaux.

Base de données : Garbage Classification Dataset - Kaggle (2 532 images)

Source : [Garbage Classification](#) taille totale : 43.4 MB Nombre d'images : 2 532 fichiers JPEG
Format : Images de déchets/objets isolés sur fond relativement uniforme

Distribution par catégorie (6 classes):

- **CARDBOARD (Carton)** : 393 images
 - Boîtes en carton, emballages carton ondulé
 - Caractéristiques visuelles : texture régulière, couleur généralement brune/grise
- **GLASS (Verre)**: 491 images
 - Bouteilles, pots, récipients en verre
 - Caractéristiques visuelles : transparence/translucidité, reflets, éclat
- **METAL (Métal)**: 400 images
 - Canettes, boîtes de conserve, objets métalliques
 - Caractéristiques visuelles : surface réfléchissante, couleur argentée/dorée
- **PAPER (Papier)**: 584 images
 - Journaux, magazines, papier blanc/imprimé
 - Caractéristiques visuelles : texture mate, surface lisse ou ondulée
- **PLASTIC (Plastique)**: 472 images
 - Bouteilles plastiques, sacs, contenants
 - Caractéristiques visuelles : surface lisse ou brillante, couleurs variées
- **TRASH (Déchets non recyclables)**: 127 images
 - Ordures diverses, matériaux non traitables
 - Caractéristiques visuelles : hétérogènes, mélange de matériaux

Particularité : Distribution déséquilibrée entre classes (TRASH avec seulement 127 images vs PAPER avec 584)

Prédiction de la Qualité du Vin selon sa Composition Chimique

Objectif de prédiction :

Développer un modèle de prédiction capable d'évaluer la qualité d'un vin (note de 0 à 10) en fonction de ses 11 caractéristiques chimiques, permettant ainsi une évaluation objective et automatisée de la qualité vinicole.

BASE DE DONNÉES : Wine Quality Dataset (1 144 observations) : Contient 12 colonnes avec les caractéristiques chimiques de chaque vin : [Wine Quality Dataset](#)

► Variables d'entrée :

- Acidité :
 - fixed acidity : acidité fixe (tartrique, malique, citrique)
 - volatile acidity : acidité volatile (acide acétique, principalement)
 - citric acid : acide citrique
- Sucres et sels :
 - residual sugar : sucre résiduel non fermenté

- chlorides : teneur en chlorure de sodium
- Conservateurs :
 - free sulfur dioxide : dioxyde de soufre libre (SO₂)
 - total sulfur dioxide : dioxyde de soufre total
- Propriétés physiques :
 - density : densité du vin
 - pH : acidité/alcalinité (0-14)
- Autres composants :
 - sulphates : sulfates (conservateurs/antioxydants)
 - alcohol : teneur en alcool (%)

► **Variable cible :**

- quality : Note de qualité du vin (0-10) (réponse à prédire)

Prédiction de l'Intensité du Trafic sur l'Autoroute I-94

OBJECTIF DE PRÉDICTION:

Développer un modèle de prédiction capable d'estimer l'intensité du trafic (nombre de véhicules) sur l'autoroute I-94 (États-Unis) à une heure donnée, en fonction des données historiques et de facteurs contextuels (conditions météorologiques, heure de la journée, jour de la semaine, jours fériés).

Base de données : I-94 Traffic Dataset [📄 Interstate Traffic Dataset \(US\)](#)

Variables disponibles (9 colonnes):

Variable cible (1):

- traffic_volume : Volume de trafic horaire (nombre de véhicules) (RÉPONSE À PRÉDIRE)

Variables temporelles (1):

- date_time : date et heure de l'observation (format : JJ/MM/AA HH:MM:SS)

Variables de calendrier extraites de date_time :

- Heure de la journée (0-23)
- Jour de la semaine
- holiday : Indicateur de jour férié (None / Holiday name) - identifie les jours fériés américains

Variables météorologiques (5):

- temp : Température (en Kelvin)
- rain_1h: Précipitations sur 1 heure (mm)
- snow_1h: Neige tombée sur 1 heure (mm)
- clouds_all : Couverture nuageuse (% de 0-100)
- weather_main : Condition météo principale (Clouds, Rain, Snow, Clear, Mist, Thunderstorm, etc.)
- weather_description : Description détaillée (scattered clouds, light rain, heavy snow, etc.)